Práctica 0: Flujo completo de Machine Learning

Izan Cuesta Corbí
DNI: 48804930B
Universidad de Alicante - Escuela Politécnica Superior
Aprendizaje Avanzado - Curso 2025/2026
Email: icc87@alu.ua.es

Resumen

Este trabajo presenta el desarrollo de un ciclo completo de Machine Learning orientado a la predicción temprana del riesgo de ictus. Para ello, se ha utilizado un conjunto de datos médico compuesto por 5110 observaciones y 12 características clínicas y demográficas. La metodología aplicada incluye un preprocesamiento exhaustivo: se han eliminado valores nulos, aplicado una transformación logarítmica al índice de masa corporal para normalizar su distribución y se han conservado los valores atípicos de glucosa teniendo en cuenta su relevancia predictiva real. Se ha realizado la codificación y estandarización, la cual hemos encapsulado dentro de un Pipeline para garantizar la ausencia de fuga de información (data leakage). Posteriormente, evaluamos un modelo de Regresión Logística optimizado mediante GridSearchCV. Dado el desbalanceo extremo de la variable objetivo (apenas un 4.3 % de casos positivos), los resultados evidenciaron el peligro de que el modelo base obtenía un 96 % de Accuracy a costa de ignorar al 100 % de los enfermos. Finalmente, al aplicar técnicas de balanceo de pesos, el modelo definitivo logró un Recall del 69 % en la clase objetivo, penalizando la precisión global (76 %) pero priorizando con éxito la sensibilidad médica para minimizar los falsos negativos.

Palabras clave: Machine Learning, Stroke Prediction, Ictus, Clasificación, Preprocesamiento, Regresión Logística

1. Introducción

1.1. Dataset Seleccionado

Para la realización de este proyecto, se ha seleccionado el Stroke Prediction Dataset (Dataset de Predicción de Ictus). La elección de este dataset se ha debido a la variedad de tipos de variables (tanto numéricas como categóricas), la existencia de valores faltantes que nos obliguen a hacer limpieza, un fuerte desbalanceo entre clases y la aplicabilidad en el mundo real. Disponible en `https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset`

1.2. Objetivo

El objetivo de este trabajo es predecir la probabilidad de que un paciente, del cual conocemos su información clínica y demográfica, sufra un accidente cerebrovascular (ictus) para así poder dar diagnósticos tempranos y poder prevenirlos.

2. Configuración Experimental

2.1. Exploración Inicial

El conjunto de datos original cuenta con un total de 5110 observaciones (pacientes) y 12 características, incluyendo la variable a predecir. Estas características se pueden agrupar según su tipología de la siguiente manera:

- **Variables numéricas continuas:** Existen tres variables relacionadas directamente con los datos biométricos de los pacientes: edad, nivel medio de glucosa y el índice de masa corporal (*bmi*). Además, se incluye una variable *id* que actúa como identificador único pero carece de valor predictivo.
- **Variables categóricas y binarias:** El conjunto contiene diversas variables categóricas de texto nominales (género, tipo de trabajo, tipo de residencia, hábito de fumar y estado civil), así como numéricas binarias que indican la presencia de condiciones médicas previas (hipertensión y enfermedades del corazón).

Las características básicas del *dataset* se resumen en la Tabla 1.

Tabla 1: Características del dataset

Característica	**Valor**
Filas	5110
Columnas	12
Var. numéricas	4
Var. categóricas	7
Variable objetivo	Stroke
Tipo problema	Clasificación

2.2. Análisis Exploratorio (EDA)

El Análisis Exploratorio de Datos que se presenta a continuación se ha realizado posteriormente a la fase inicial de limpieza de datos, tratamiendo de valores nulos, outliers extremos y codificación de variables.

2.2.1. Estadística Descriptiva

Tabla 2: Estadísticas descriptivas

Var.	**Media**	**Std**	**Min**	**Max**
Edad	42.87	22.56	0.08	82.00
Glucosa	105.30	44.43	55.12	271.74
BMI (Log)	3.36	0.26	2.42	4.59

2.2.2. Distribuciones

En la Figura 1 se muestra la distribución que siguen las variables numéricas del *dataset* (edad, glucosa y bmi (log)).

- **Distribución *age*:** Es una distribución bastante plana con una gran cantidad de ejemplos entre los 40 y 60 años. Lo más destacable es el pico final en los 80 años, que puede deberse al tope del dataset donde se han incluido a todos los mayores de 80 en la misma categoría.

- **Distribución *avg_glucose_level*:** Es una distribución asimétrica hacia la derecha donde se acumulan la gran mayoría de personas al principio en los valores normales de glucosa (sobre el 80). Lo que destaca es la cola hacia la derecha que va disminuyendo pero tiene un repunte cuando llega a 200, donde se establece un límite de gravedad en los pacientes y todos los que pertenezcan a ese rango en adelante tienen motivos por los que pudieran sufrir un ictus (son los outliers que no hemos eliminado en el tratamiento de los datos porque aportaban información clave en el estudio).

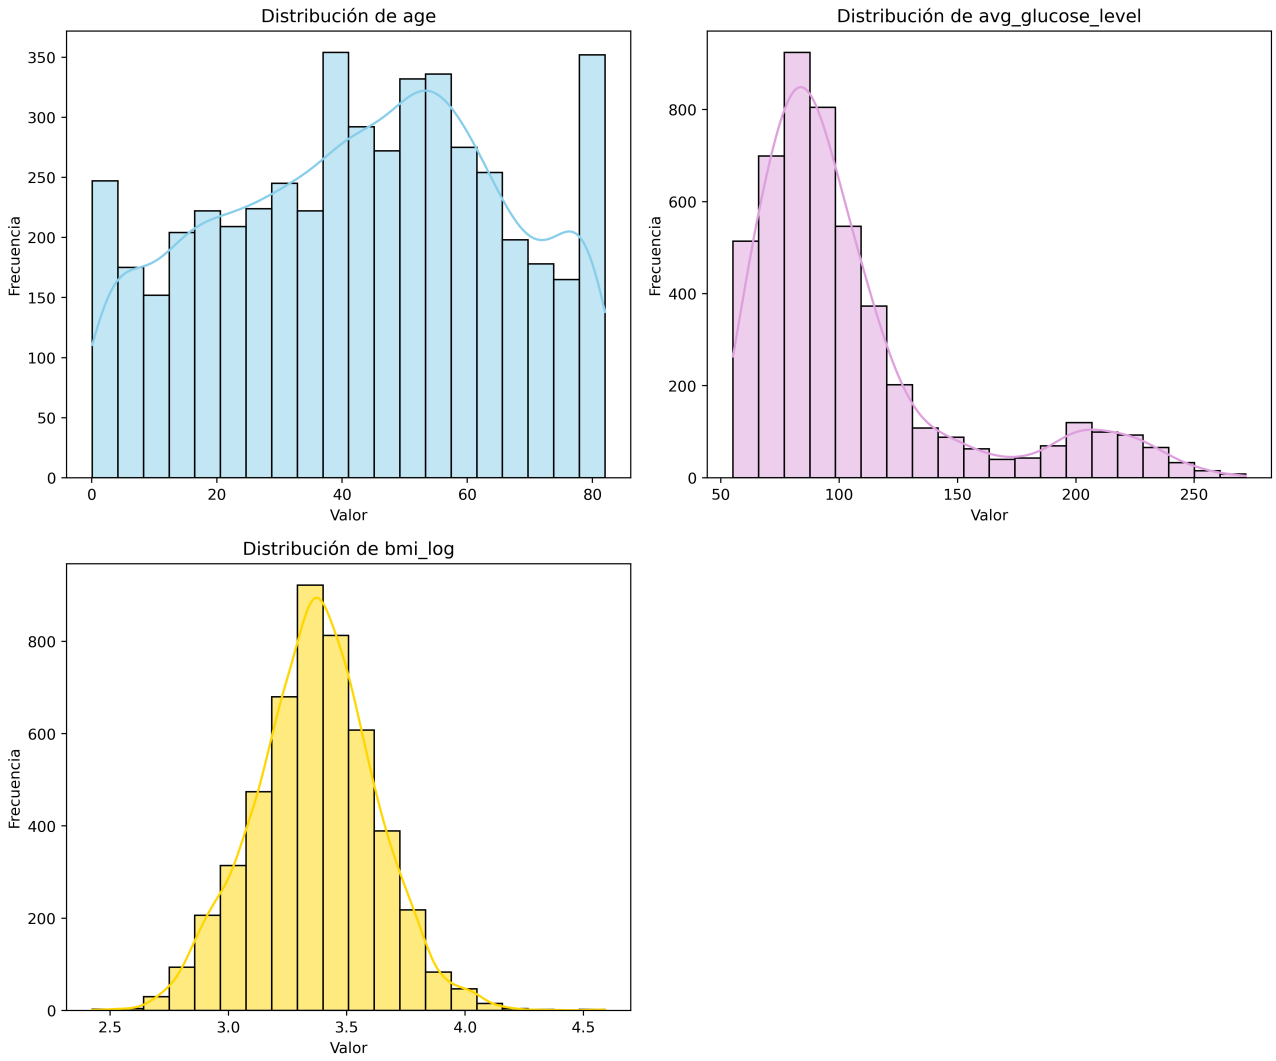


Figura 1: Distribuciones principales

- **Distribución *bmi_log*:** Al haber realizado la transformación logarítmica sobre la variable, hemos convertido la curva de la gráfica en una campana de Gauss (distribución normal) que de no haber aplicado seguiría siendo una cola larga hacia la derecha como es el caso de la glucosa. El pico lo obtenemos sobre el valor 3.3 y al ser normal tenemos una desviación mínima (se concentra todo).

2.2.3. Correlaciones

En la matriz de correlación observamos que ninguna de las variables numéricas presenta una alta correlación entre sí. La relación más destacada se da entre *age* y *bmi_log* con un coeficiente de 0.40. Al igual que en las otras combinaciones, se trata de una correlación positiva pero débil.

Esta ausencia de correlaciones fuertes es muy positiva para el modelo predictivo, ya que descarta problemas de multicolinealidad. Desde un punto de vista médico aunque la edad, el peso y la glucosa están relacionados con la salud general, miden procesos fisiológicos independientes que no siempre aumentan de forma simultánea.

En la Figura 2 se muestra la matriz de correlación entre las variables numéricas del dataset.

2.2.4. Balance de Clases

Pacientes sanos: 4699 - Pacientes con riesgo de sufrir un ictus: 209

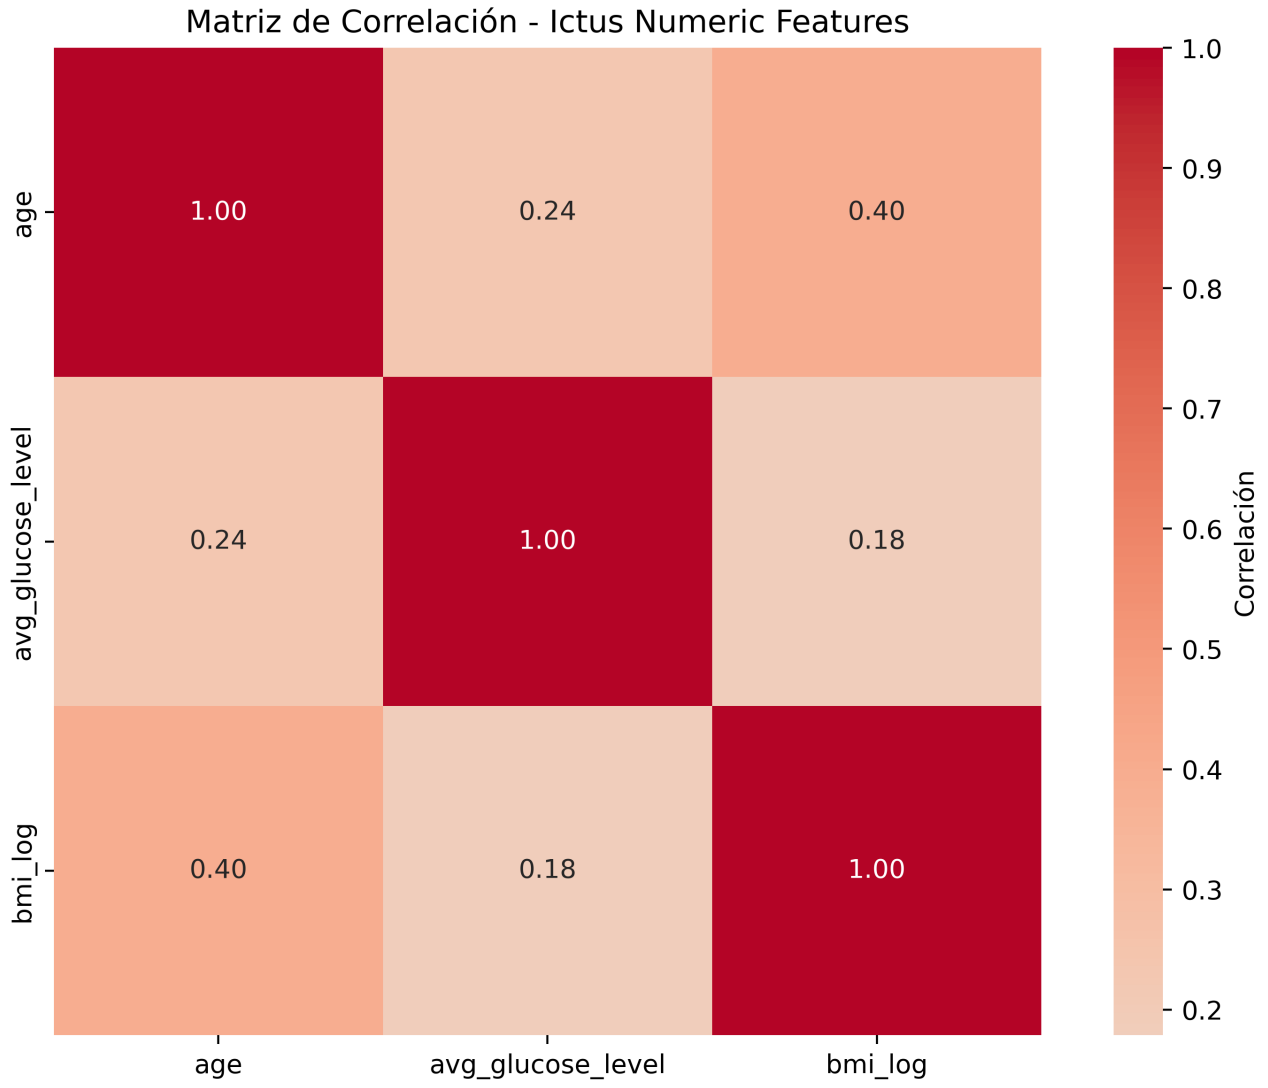


Figura 2: Correlaciones

Como podemos ver en esta gráfica, el dataset está extremadamente desbalanceado. Esto tiene una explicación lógica ya que la proporción de personas que sufren un ictus es muy pequeña en comparación a las que no, ya que no suele ser algo muy común. Al tener un dataset tan desbalanceado tendremos que tener cuidado con las métricas de accuracy con las que trabajaremos posteriormente, porque al tener la variable objetivo con un porcentaje tan bajo (4.2584 %) podrán engañar con su resultado, ya que ante la duda lo más sencillo será responder que la persona analizada no ha sufrido ningún ictus.

En la Figura 3 se muestra la proporción de pacientes sanos y pacientes con riesgo de ictus.

2.2.5. Hallazgos del EDA

Tras realizar el Análisis Exploratorio de Datos, he extraído las siguientes conclusiones clave que han guiado las decisiones de preprocesamiento y modelado:

- **Desbalance extremo de la variable objetivo:** La clase a predecir (*stroke*) presenta un gran desequilibrio, con un 95.7 % de pacientes sanos frente a un 4.3 % de pacientes que han sufrido un ictus. Es por ello que métricas como el *Accuracy* no serán fiables, se tendrá que hacer uso de técnicas de balanceo en el algoritmo y por tanto darle más importancia a la evaluación mediante *F1-Score* y *Recall*.
- **Ausencia de multicolinealidad:** Ninguna de las variables numéricas presenta una correlación fuerte entre sí (la máxima es de 0.40 entre la edad y el *bmi_log*). Esto es muy positivo para

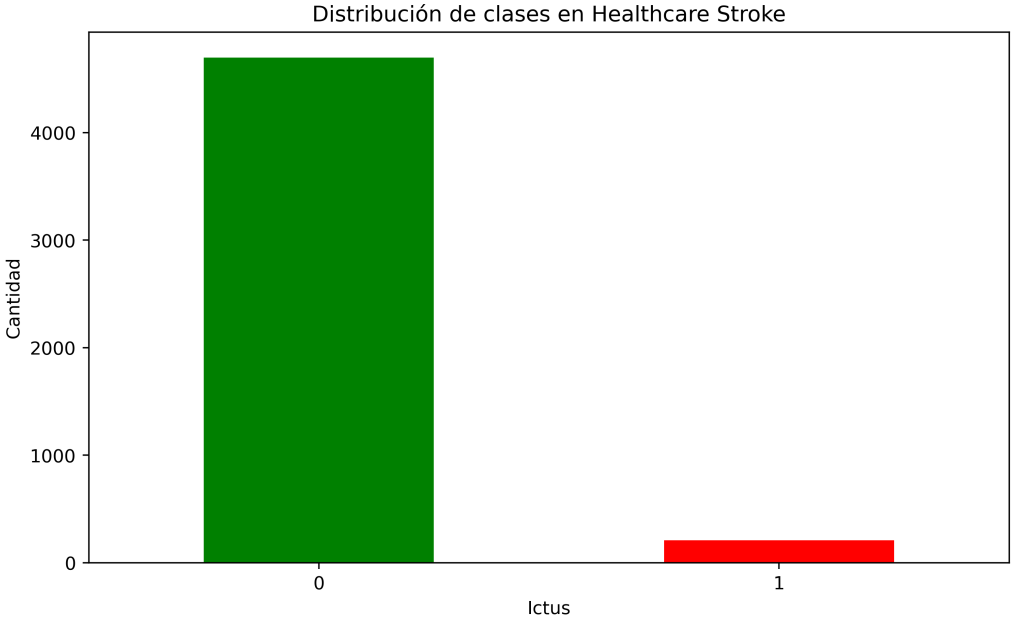


Figura 3: Variable objetivo

el modelo, ya que indica que cada variable aporta información única e independiente sobre el paciente.

- **Distribuciones asimétricas y valores clínicos extremos:** Variables como el nivel de glucosa presentan una fuerte asimetría hacia la derecha con un repunte en valores superiores a 200. Determinamos que no son errores en la recolección de los datos, sino estados de riesgo crítico (como la diabetes), por lo que se ha decidido conservarlos para no perder información vital.

2.3. Preprocesamiento

2.3.1. Valores Faltantes

La variable *bmi* es la única del dataset que contiene filas con valores faltantes, más concretamente 201 tras la exploración inicial. Es por ello que al tratarse de menos del 5 % de observaciones del conjunto de datos, he decidido eliminar esas filas para trabajar únicamente con datos reales y evitar el sesgo introducido por otras técnicas como la imputación.

2.3.2. Outliers

De las tres variables numéricas, hemos detectado outliers en dos de ellas:

- **Edad:** Es la variable que no contiene outliers. Todos sus valores entran dentro de un rango común para los años de una persona, yendo desde los recién nacidos (0) hasta personas ancianas sobrepasando los 80.

- **Bmi:** Es una medida estándar que utiliza la estatura y el peso para clasificar a las personas. Mientras la mayoría de la población se concentra entre 20 y 40, existen outliers extremos con valores de hasta 97.6. Estos representan casos extremos de obesidad que, pese a que pueden ser reales, pueden llegar a distorsionar el aprendizaje del modelo, ya que un valor de BMI mayor de 40 ya está representando la obesidad mórbida, correspondiendo al último caso dentro de su rango de clasificación (el más grave). Por tanto, todo lo que esté por encima ya será tremendamente nocivo para la salud y no habrá una grandísma diferencia entre los propios casos de obesidad mórbida.

  Para ajustar los outliers, he aplicado una transformación logarítmica que comprime los valores extremos, permitiendo que el modelo considere estos casos como riesgo alto"sin que un valor de

97 tenga un peso desproporcionado frente a un valor de 45. En la gráfica posterior, se mostrará la detección de los outliers una vez aplicada la transofrmación logarítmica.

- **Nivel de glucosa:** Representa la concentración media de azúcar en sangre. Es un indicador directo del metabolismo y la diabetes, donde muchos pacientes tienen valores normales entre 80 y 100, pero se detecta un grupo significativo de outliers con valores entre 200 y 271. Desde el punto de vista médico, los valores de glucosa por encima de 200 mg/dL indican una diabetes severa en el paciente.

  A diferencia del BMI, en los outliers de glucosa una diferencia entre valores altos si que indica un peligro mucho mayor, por lo que si se transformasen los valores estaríamos ocultando al modelo la gravedad del estado del paciente. En este caso, para esta variable categórica no realizaremos ninguna transformación, ya que estaríamos perdiendo datos importantes al hacer la predicción.

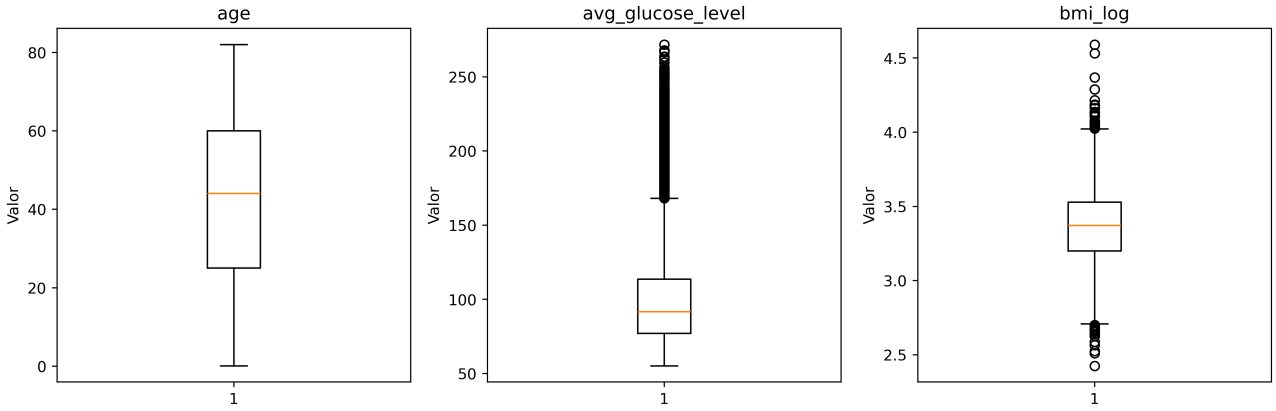


Figura 4: Detección de outliers

2.3.3. Transformaciones

- **Escalado:** StandardScaler.

  Un punto importante de la estandarización, es haberla pospuesto hasta haber realizado los splits de entrenamiento y test que comentaré posteriormente.

  Una de las razones por las que me he decantado por el método del StandardScales ha sido la transformación que he realizado en el paso anterior a la variable *bmi*. Al aplicarle una transformación logarítmica hemos convertido la distribución del BMI en una distribución normal, lo que potencia el uso de Standard Scaler, que es la técnica por defecto para modelos lineales.

  Respecto a las otras dos variables numéricas, la estandarización respetará los outliers en la variable *avg_glucose_level* para que se mantenga esa diferencia importante en los resultados y en *age* no ocurrirá ningún problema ya que es una variable estándar.

- **Categóricas:** Label Encoding y One-Hot Encoding.

  En las variables binarias (*ever_married, residence_type, gender*), utilizamos Label Encoding, conviertiendo Casado(1)/No casado(0), Urbana(1)/Rural(0) y Hombre(1)/Mujer(0). Para las variables binarias, el uso de Label Encoding y One-Hot Encoding es práctimente el mismo ya que no se le está pasando como parámetro un orden, sino la presencia o no de la variable, por lo que he decidido usarla para probar más de una técnica.

  En el caso de la variable gender, no era binaria sino que tenía tres respuestas (*male, female, other*). Sin embargo, solo existía una observación con la categoría *other*, por tanto en el apartado de la limpieza de valores faltantes decicí eliminarla para hacer más sencilla la codificación.

  En el caso de *smoking_status*, inicialmente había considerado usar Label Encoding bajo la hipótesis médica de que fumar aumenta el riesgo progresivamente, siendo el orden lógico: *never smoked*

< *formerly smoked* < *smokes*. Sin embargo, al analizar los datos, se observa que la categoría 'formerly smoked' presentaba mayor riesgo de ictus en esta muestra que *smokes* (posiblemente debido a la edad o condiciones preexistentes de quienes dejan de fumar), siendo los resultados:

- formerly smoked: 7.9

- smokes: 5.3

- never smoked: 4.8

- Unknown: 3.0

Además, la presencia de la categoría *Unknown* no permite establecer un orden lineal claro y tendríamos que no darle ningún valor o inventárnoslo. Por ello, he optado por One-Hot Encoding para tratar cada categoría de forma independiente sin introducir sesgos de orden incorrectos y sin asumir ningún orden.

En el caso de *work_type*, directamente no existe ningún orden intrínseco, por lo que son categorías nominales y también usaremos One-Hot Encoding.

2.4. Train-Test Split

Para la división de los datos he hecho una proporción 80-20, donde el 80 % de las observaciones se agrupan para el conjunto de entrenamiento y el 20 % restante se utiliza en el conjunto de test. Usaremos la condición *stratify* para que cada split tenga una proporción similar de las clases y lo realizaremos en la semilla 42.

Tabla 3: División de datos

Conjunto	**N**	**%**	**N Ictus**	**% Ictus**
Train	3926	80	167	4.25
Test	982	20	42	4.28

2.5. Pipeline

Este pipeline encapsula el preprocesamiento y el entrenamiento en un único flujo de trabajo automatizado que consta de dos pasos secuenciales:

1. Estandarización:

   Se estandarizan las variables de entrada para que todas compartan la misma escala y tengan el mismo peso durante el entrenamiento.

2. Modelo de Regresión Logística:

   Aplica el algoritmo de predicción utilizando el parámetro class_weight='balanced', lo que permite al modelo penalizar automáticamente los errores sobre la clase minoritaria (ictus) para compensar el desbalance de los datos.

```
pipe = Pipeline([
    ('scaler', StandardScaler()),
    ('model', LogisticRegression(class_weight='balanced', random_state=42))
])
```

El objetivo principal de integrar estos pasos en un Pipeline es evitar la fuga de información (data leakage) durante la validación cruzada. De este modo, garantizamos que en cada iteración del Grid Search, el escalado de los datos se calcule exclusivamente sobre los pliegues de entrenamiento, sin mezclarse con la información de los datos de validación.

```
grid = GridSearchCV(pipe_grid, param_grid, cv=5, scoring='f1_weighted', n_jobs=-1)
grid.fit(X_train, y_train)
```

2.6. Balanceo de Pesos en el Modelo

Al tener un dataset tan desbalanceado, el modelo sabe por defecto que aproximadamente el 95 % de los pacientes del dataset están sanos y no han sufrido un ictus, por lo que podría basarse en dar como negativo la mayoría de los casos y aún así seguiría teniendo un buen resultado. Esto lo que nos da son unos resultados falsos y que solo se basan en el porcentaje general de ictus en el conjunto completo de los datos, pero sin importarle si el diagnóstico de cada paciente está bien o no (el cual fallará prácticamente siempre). Es por ello que el uso del parámetro class_weight='balanced' dentro del modelo, obliga al algoritmo a predecir cada paciente por igual a pesar del rendimiento general equilibrando los pesos de cada uno.

2.7. Parámetros Evaluados

Tabla 4: Parámetros para Regresión Logística

Párametros	**Valores**
C	0.01, 0.1, 1, 10
Max_Iter	1000, 2000

2.8. Métricas

Al tratarse de un problema de clasificación, hemos utilizado **Accuracy**, **Precision**, **Recall** y **F1**, haciendo más énfasis en estas dos últimas dadas las condiciones de nuestro dataset.

3. Resultados

3.1. Comparación de Modelo Balanceado y No Balanceado

Tabla 5: Resultados

Balanceo	**Var. Obj.**	**Acc**	**Prec**	**Rec**	**F1**
Sí	0	.76	.98	.76	.86
Sí	1	.76	.11	.69	.19
No	0	.96	.96	1.00	.98
No	1	.96	.00	.00	.00

- Para el **modelo balanceado** obtenemos un accuracy del 0.7576. Con esta información y sabiendo que habíamos activado el parámetro de 'class_weight', tenemos un modelo sensible que está sobreestimando la cantidad de pacientes con riesgo de ictus, dando falsos positivos antes que falsos negativos. Esto en términos médicos podría ser clave, ya que se estaría primando el dar falsas alarmas a gente cercana a un posible ictus pero sin riesgo, que dejar pasar diagnósticos de pacientes que si que tengan un riesgo evidente y que el modelo no detecte, ya que en medicina, un falso positivo se puede descartar posteriormente al hacer pruebas al paciente, pero un falso positivo puede ser mortal.

  En el resto de métricas, nos vamos a fijar más a fondo en el 'recall', que parte de la premisa que acabo de comentar. Hemos obtenido un recall del 71 % para la clase de personas con riesgo de ictus, lo que quiere decir que es capaz de identificar correctamente a más de 7 de cada 10 pacientes en riesgo real. El contrario a este dato lo obtenemos en la métrica de 'precisión', donde para esta misma clase solo obtenemos un 12 % que nos indica la gran tasa de falsos positivos que se han detectado.

- Para la **versión desbalanceada**, el accuracy ha sido de 0.9572, lo que nos indica que se ha hecho la predicción tal y como comentaba en el apartado anterior. Pese a que este accuracy sea tan elevado, no tiene ninguna fundamentación con las características del dataset, ya que ha predecido que nadie tiene riesgo de ictus en un dataset en el que casi nadie tiene riesgo de ictus, por lo que se esta mostrando un resultado falsamente elevado.

  Analizando el resto de métricas, nos fijamos otra vez en el recall y la precisión. El recall para la clase 1 es de 0, por lo que de todos los pacientes que estaban sufriendo un ictus no ha detectado a ninguno y un 1 en la clase 0, diciendo que el 100 % de los pacientes del dataset está sano. En la precisión también se ha dado un 0 para la clase 1, al no haber dado ninguna alarma de ictus y un 0.96 para la clase 0, debido a los pacientes graves que no se han detectado al igual que en el accuracy.

3.2. Matriz de Confusión

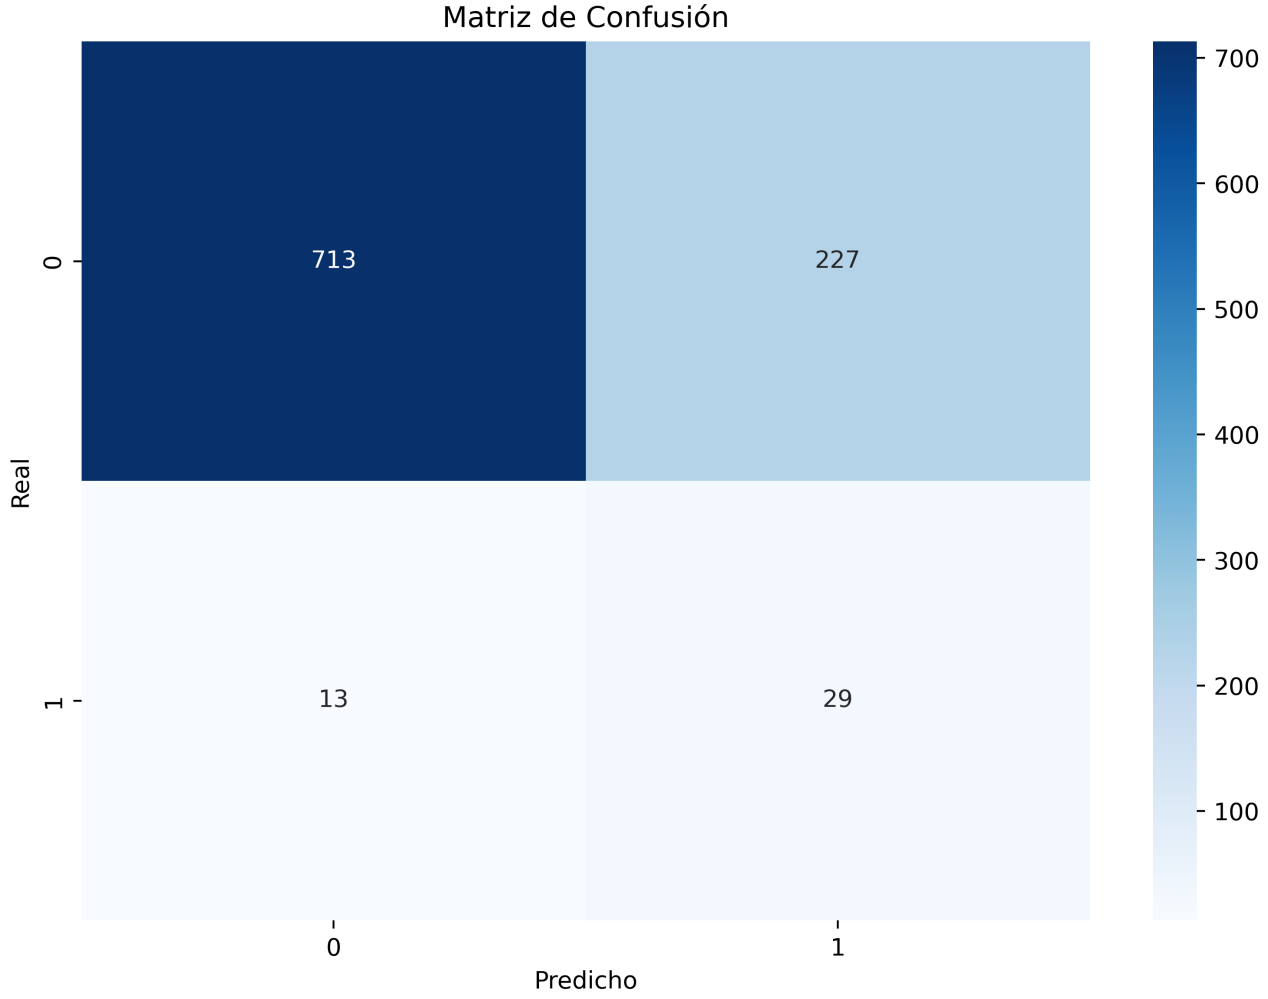


Figura 5: Confusión - mejor modelo

En la diagonal principal podemos ver los pacientes que se han ajustado a su diagnóstico real y en la diagonal alternativa los errores de clasificación que ha tenido el modelo:

- Verdaderos negativos: 714 pacientes sanos que se han clasificado como sanos.
- Falsos positivos: 226 pacientes sanos que se han clasificado como pacientes de riesgo.
- Falsos negativos: 12 pacientes de riesgo que se han clasificado como sanos.

- Verdaderos positivos: 30 pacientes de riesgo que se han clasificado como pacientes de riesgo.

El número clave de esta matriz es el de los falsos negativos (12), ya que son los pacientes a los que se les da un diagnóstico falso que puede llevar a un ictus sin haber recibido tratamiento.

3.3. Validación Cruzada

- Accuracy: 0.7583 ± 0.0206
- F1-Score: 0.8297 ± 0.0139

3.4. Optimización

Tabla 6: Mejores hiperparámetros

Parámetro	**Valor**
C	10.0
max_iter	1000

3.5. Comparación entre Versiones del Dataset

Tabla 7: Resultados en distintos datasets (Variable Objetivo)

Versión	**Acc**	**Prec**	**Rec**	**F1**
Base	.75	.11	.67	.19
Limpia	.75	.11	.69	.19
Outliers	.76	.11	.69	.19
Codificada/Final	.76	.11	.69	.19

Como podemos ver en la tabla, al realizar la ejecución de un pipeline base con los mejores hiperparámetros, introduciendo la codificación y estandarización necesarias para su funcionamiento (y la eliminación de valores faltantes previa en la versión base para que se pudiese ejecutar la regresión logística), las diferencias observadas son muy pequeñas entre un dataset y otro. Es tan poca la diferencia que las dos últimas versiones acaban dando los mismos resultados porque el pipeline las ha convertido prácticamente en la misma. Como valores que cambian, de la versión 1 a la 2 se suman dos centésimas en la categoría de Recall y de la versión 2 a la 3 se suma una centésima en el Accuracy.

Pese a que simple vista puedan parecer cambios muy pequeños, en términos médicos podrián ser claves para salvar o dar un mejor diagnóstico a un mayor número de pacientes.

4. Análisis y Discusión

El análisis de los resultados revela que el modelo definitivo (Regresión Logística con el hiperparámetro C=10, max_iter=1000 y pesos balanceados) representa la solución más sólida para el problema con el que estamos trabajando. Tal y como hemos visto durante la exploración de datos, guiarse únicamente por el Accuracy resultaba engañoso, ya que el modelo base sin balancear alcanzaba un 96 % de precisión a costa de ignorar por completo a los enfermos (0 % de Recall en la clase 1). Al aplicar class_weight='balanced', logramos un modelo que detecta correctamente al 69 % de los pacientes en riesgo de sufrir un ictus. El análisis de errores demuestra que este aumento en la sensibilidad del modelo nos lleva a generar un alto volumen de falsos positivos (la precisión para la clase 1 es del 11 %). Para un contexto médico preventivo como el que tenemos en la práctica, este comportamiento es clave, priorizando la detección temprana y así minimizar los falsos negativos, resultando mucho más seguro que dejar a pacientes en riesgo sin diagnosticar.

El preprocesamiento de los datos que hemos llevado a cabo se ha basado en la transformación logarítmica aplicada al índice de masa corporal (bmi_log) y la estandarización de las variables numéricas, que han sido claves para que la Regresión Logística pudiera asignar pesos de forma equilibrada sin sesgarse por los outliers de la glucosa. Asimismo, la principal ventaja de haber encapsulado estos pasos en un Pipeline integral ha sido la prevención absoluta de la fuga de información (data leakage) durante las particiones del GridSearchCV, lo que nos garantiza que las métricas obtenidas son completamente reales y representativas del mundo real.

A pesar de estos logros, el enfoque actual presenta ciertas limitaciones. La principal barrera es el desbalanceo extremo del dataset original (apenas un 4.3 % de casos positivos), lo que dificulta enormemente que un algoritmo lineal encuentre una frontera de decisión clara entre las clases sin tener que lanzar los falsos positivos.

5. Conclusiones

El desarrollo de este proyecto ha permitido cumplir con éxito el objetivo de construir un sistema predictivo para el riesgo de ictus, pero sobre todo, ha revelado un hallazgo fundamental sobre el tratamiento de datos médicos. Hemos demostrado empíricamente que, en el ámbito de la salud, partes del ruido o valores atípicos (como los picos extremos en los niveles de glucosa) mostrados en el conjunto de datos, constituye en realidad la señal predictiva más valiosa. El principal descubrimiento ha sido comprender que la estandarización y limpieza de datos deben aplicarse sabiendo el tipo de objetivo que estamos buscando, preservando la información clínica crítica y transformando solo las variables que lo necesiten (como la transformación logarítmica del BMI) es lo que verdaderamente ayuda al algoritmo a encontrar patrones de riesgo.

A nivel de rendimiento, el modelo final basado en Regresión Logística ha cumplido el objetivo de priorizar la sensibilidad en un entorno médico, logrando identificar a la mayoría de los pacientes vulnerables gracias al balanceo de clases. Además del algoritmo elegido, el mayor aprendizaje extraído del flujo de Machine Learning ha sido la introducción de los Pipelines. Encapsular los procesos de codificación y escalado junto con el estimador final ha convertido un conjunto de tareas sueltas en una arquitectura robusta.

De cara a futuras mejoras, el proyecto tiene margen de evolución. En primer lugar, para evitar el desequilibrio extremo de las clases sin generar tantos falsos positivos, se podría experimentar con técnicas de generación de datos sintéticos para equilibrar las clases antes de entrenar. En segundo lugar, una opción de mejora podría ser sustituir el modelo lineal actual por algoritmos basados en árboles de decisión como Random Forest o probar con un modelo como SVM, ya que poseen otras muchas cualidades y capacidades que pueden potenciar las relaciones complejas y no lineales entre las distintas variables biométricas del paciente. Todo ello como parte del experimento y viendo si su implementación mejoraría lo que tenemos hasta ahora.